



Exercício #01

Analisando os dados a partir da matriz de correlações abaixo, conclui-se que não há apenas forte associação linear entre Y e as covariáveis do dataset, mas também colinearidade entre os próprios preditores. Esse fator é importante: colinearidade excessiva infla artificialmente o R^2 e mascara os efeitos reais dos estimadores.

```
library(openxlsx)
dados <- read.xlsx("ModeloVigente_DadosCP62_2023.xlsx")
```



(a) Matriz de correlação



(b) Distribuições de densidade

Figure 1: Análise exploratória de dados

Além disso, a distribuição das variáveis numéricas intui um formato análogo entre elas: uma típica assimetria à direita, ou seja, oportunidade para uma transformação $\log - \log$ para estabilizar a variância e prevenir heterocedasticidade. A transformação é cabível em ambos os lados da equação, pois todos possuem a mesma assimetria, resultando em um modelo da seguinte forma:

$$\ln(Y_i) = \beta_0 + \beta_k \ln(X_{ki}) + u_i$$

Após a análise exploratória, levantamos através do estudo da “inflação de variância (VIF)” quais preditores são mais “perigosos” ao modelo por inflar o R^2 artificialmente e elaboramos dois modelos (com ou sem essas variáveis):

Table 1: Análise de multicolinearidade (VIF)

Variável	VIF
$\log(\text{cons} + 1)$	88.05
$\log(\text{mercado_p} + 1)$	86.74
$\log(\text{rede_aerea} + 1)$	16.92
$\log(\text{rede_alta} + 1)$	10.22
$\log(\text{pnt} + 1)$	4.31
$\log(\text{chi} + 1)$	3.78
$\log(\text{rede_subterranea} + 1)$	3.05

```
library(reglin)
library(broom)
library(modelsummary)
mod_1 <- lm(log(pms0+1) ~
  log(rede_subterranea+1) +
  log(chi+1) +
  log(pnt+1)
  ,data=dados
)
glance_custom.lm <- function(x) {
  out <- broom::glance(x)
```

```

# Criamos uma coluna nova com um nome que não tenha erro
out$p_global <- out$p.value
return(out)
}
meu_mapa_gof <- list(
  list("raw" = "adj.r.squared", "clean" = "R² ajustado", "fmt" = 3),
  list("raw" = "p_global", "clean" = "P-valor (F)", "fmt" = "%.2e")
)
modelos <- list(
  "Original" = mod,
  "Log-Log" = mod_1
)
modelsummary(modelos,
  fmt = 3,
  estimate = "{estimate}{stars}",
  statistic = "std.error",
  gof_map = meu_mapa_gof,
  metrics = "all",
  include_empty = TRUE,
  title = "Comparação de Modelos")

```

Table 2: Comparação de Modelos

	Original	Log-Log
(Intercept)	1.591**	7.597***
	(0.534)	(0.399)
log(rede_alta + 1)	0.024	
	(0.032)	
log(rede_subterranea + 1)	0.027	0.134*
	(0.018)	(0.051)
log(rede_aerea + 1)	0.217***	
	(0.057)	
log(mercado_p + 1)	0.414**	
	(0.141)	
log(cons + 1)	0.109	
	(0.135)	
log(chi + 1)	0.007	0.107***
	(0.009)	(0.028)
log(pnt + 1)	0.078***	0.275***
	(0.020)	(0.059)
R² ajustado	0.987	0.843
P-valor (F)	1.12×10^{-40}	5.91×10^{-20}

Tendo em vista os resultados, ambos são globalmente significativos. No entanto, optamos por seguir com o modelo mais simples que, apesar de um R^2 mais enxuto, exclui as variáveis que inflam essa medida artificialmente e propõe melhor significância estatística para as features individualmente. Em termos de explicabilidade, não há prejuízos, mas uma mudança de perspectiva e escala: em um modelo $\log - \log$ os coeficientes expressam a elasticidade de Y dado X , ou seja, estamos falando sobre o quanto Y reage percentualmente às variações percentuais nos preditores. Analisando os resíduos e a influência, obtivemos que:

Graficamente, não há evidência de quebra dos pressupostos dos modelos lineares quanto aos resíduos. Todavia, os testes formais podem dar mais detalhes:




Figure 2: Resíduos




Figure 3: Influência

Shapiro-Wilk normality test

W p.value
0.98 0.5249

Non-constant Variance Score Test

Variance formula: ~ fitted.values

Chisquare = 8.564381, Df = 1, p = 0.003428

Durbin-Watson Test for Autocorrelated Errors

lag Autocorrelation D-W Statistic p-value
1 0.08429418 1.764442 0.354

Alternative hypothesis: rho != 0

Bonferroni Outlier Test

No Studentized residuals with Bonferroni p < 0.05

Largest |rstudent|:

rstudent unadjusted p-value Bonferroni p
40 3.340994 0.0016429 0.085429

Figure 4: Diagnóstico formal de observações influentes

ID	Cook	Hat	Res.Std	Inter.	Rede	Chi	Pnt
40	0.359	0.135	3.035	1.137	-0.047	0.778	-1.090
52	0.136	0.131	-1.902	-0.564	0.135	-0.539	0.587
51	0.077	0.135	1.406	-0.021	-0.086	-0.465	0.331
24	0.077	0.120	1.505	-0.133	-0.476	0.284	0.098
50	0.073	0.285	0.855	0.538	0.193	0.110	-0.447

A observação 50 apresentou a maior alavancagem do modelo. Ao investigar o dado original, identificou-se que esta distribuidora reportou valor zero para Perdas Não Técnicas (PNT), um comportamento atípico no cenário nacional de distribuição de energia. Para evitar que esta especificidade distorcesse as elasticidades globais, optou-se pelo isolamento deste ponto e também do 40, que explode o limite da a distância de cook, via variável dummy.

```
n <- nrow(dados)
limite_cook <- 4/n

dados_refinado <- dados %>%
  mutate(
    dummy_id40 = ifelse(row_number() == 40, 1, 0),
    dummy_id50 = ifelse(row_number() == 50, 1, 0)
  )

mod_final <- lm(log(pms0 + 1) ~
  log(rede_subterranea + 1) +
  log(chi + 1) +
  log(pnt + 1) +
  dummy_id40 +
  dummy_id50,
  data = dados_refinado)
```

Table 3: Comparação de Modelos

	Log-Log	Log-Log (sem influencia)
(Intercept)	7.597*** (0.399)	6.740*** (0.454)
log(rede_subterranea + 1)	0.134* (0.051)	0.118* (0.047)
log(chi + 1)	0.107*** (0.028)	0.079** (0.026)
log(pnt + 1)	0.275*** (0.059)	0.390*** (0.064)
dummy_id40		2.715*** (0.733)
dummy_id50		1.398+ (0.806)
R ² ajustado	0.843	0.876
P-valor (F)	5.91×10^{-20}	1.01×10^{-20}

Verificando métricas de erro e influência novamente:

Table 4: Teste F Parcial

Modelo	GL Res.	RSS	Df	Soma Quadr.	F	p-valor
Modelo 1 (Simples)	48	26.8744	NA	NA	NA	NA
Modelo 2 (Com Dummies)	46	20.3844	2	6.4901	7.3228	0.0017

Conclusão:

O modelo final apresentou diagnóstico mais robusto na comparação de modelos via ANOVA, atendendo integralmente aos pressupostos clássicos da regressão linear. Adicionalmente, a ausência de outliers significativos via teste de Bonferroni valida a estratégia de isolamento das observações atípicas por variáveis dummy.




Figure 5: Resíduos




Figure 6: Influência

- Log(PNT) - é o maior impacto: um aumento de 1% nas Perdas Não Técnicas (fraudes) eleva o custo operacional esperado de ~0.39%. Isso faz todo o sentido, pois combater “gatos” exige equipe e fiscalização.
- Log(chi) - se a interrupção de energia subir 1%, o custo sobe ~0.08%. Mostra que manter a continuidade custa dinheiro.
- Log(Rede Sub.) - redes subterrâneas são mais caras de manter; um aumento de 1% na rede eleva o custo em ~0.12%.
- ID 40: o coeficiente de 2.714 é gigantesco e super significativo ($p < 0.001$). Isso confirma que o ID 40 era uma anomalia. Sem essa dummy, esse valor estaria “sujando” todos os outros coeficientes. Ele gasta muito mais do que o tamanho dele justificaria.

Exercício 2

```
df <- read.table("danishlrc.dat", header = TRUE)
df$Age <- factor(df$Age,
                 levels = c("40-54", "55-59", "60-64", "65-69", "70-74", ">74")
                 )
df$City <- factor(df$City)
library(modelsummary)
datasummary_skim(df, fmt = 2)
```

	Unique	Missing Pct.	Mean	SD	Min	Median	Max	Histogram
Cases	13	0	9.33	3.16	2.00	10.00	15.00	
Pop	24	0	1100.33	842.23	509.00	791.00	3142.00	
		N	%					
Age	40-54	4	16.67					
	55-59	4	16.67					
	60-64	4	16.67					
	65-69	4	16.67					
	70-74	4	16.67					
	>74	4	16.67					
City	Fredericia	6	25.00					
	Horsens	6	25.00					
	Kolding	6	25.00					
	Vejle	6	25.00					

A densidade da variável *pop* é assimétrica à direita, e o sentido de colocá-la no modelo não pode ser como preditor, porque a população não pode ser interpretada como um fator de risco, mas como um “denominador” no qual o qual o risco é calculado, de forma que os coeficientes como a *Age* representem que estar numa faixa etária X aumenta/diminui a taxa de incidência em Y%. Isso tira o efeito do tamanho da cidade para que seja possível focar nas outras covariáveis com apelo causal.

```
library(tidymodels)
library(poissonreg)

mod =
  poisson_reg() %>%
  set_engine("glm") %>%
  set_mode("regression")

wf =
  workflow() %>%
  add_recipe(recipe(Cases ~ Pop + Age + City, data = df)) %>%
  add_model(mod)

wf %>% fit(data = df)
```

```
== Workflow [trained] =====
Preprocessor: Recipe
Model: poisson_reg()
```

```
-- Preprocessor -----
0 Recipe Steps
```

```
-- Model -----
```

```
Call: stats::glm(formula = ..y ~ ., family = stats::poisson, data = data)
```

Coefficients:

```
(Intercept)      Pop      Age55-59      Age60-64      Age65-69      Age70-74
  3.2128418 -0.0003412 -0.6973716 -0.4398872 -0.4459548 -0.6085898
      Age>74 CityHorsens CityKolding CityVejle
 -0.8251288 -0.0460603 -0.1860295 -0.2363857
```

Degrees of Freedom: 23 Total (i.e. Null); 14 Residual
Null Deviance: 27.7
Residual Deviance: 20.45 AIC: 136.8

```
mod_pois_v2 <- glm(Cases ~ Age + City,  
  family = poisson(link = "log"),  
  offset = log(Pop),  
  data = df)  
summary(mod_pois_v2)
```

Call:

```
glm(formula = Cases ~ Age + City, family = poisson(link = "log"),  
  data = df, offset = log(Pop))
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.6321	0.2003	-28.125	< 2e-16 ***
Age55-59	1.1010	0.2483	4.434	9.23e-06 ***
Age60-64	1.5186	0.2316	6.556	5.53e-11 ***
Age65-69	1.7677	0.2294	7.704	1.31e-14 ***
Age70-74	1.8569	0.2353	7.891	3.00e-15 ***
Age>74	1.4197	0.2503	5.672	1.41e-08 ***
CityHorsens	-0.3301	0.1815	-1.818	0.0690 .
CityKolding	-0.3715	0.1878	-1.978	0.0479 *
CityVejle	-0.2723	0.1879	-1.450	0.1472

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 129.908 on 23 degrees of freedom
Residual deviance: 23.447 on 15 degrees of freedom
AIC: 137.84

Number of Fisher Scoring iterations: 5